

广西师范大学学报(自然科学版)

Journal of Guangxi Normal University(Natural Science Edition)

ISSN 1001-6600,CN 45-1067/N

## 《广西师范大学学报(自然科学版)》网络首发论文

题目: 基于优化极限学习机的公交行程时间预测方法  
作者: 许伦辉, 苏楠, 骈宇庄, 林培群  
DOI: 10.16088/j.issn.1001-6600.2020073102  
收稿日期: 2020-07-31  
网络首发日期: 2021-01-05  
引用格式: 许伦辉, 苏楠, 骈宇庄, 林培群. 基于优化极限学习机的公交行程时间预测方法. 广西师范大学学报(自然科学版).  
<https://doi.org/10.16088/j.issn.1001-6600.2020073102>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI:10.16088/j.issn.1001-6600.2020073102

# 基于优化极限学习机的公交行程时间预测方法

许伦辉\*, 苏楠, 骈宇庄, 林培群

(华南理工大学 土木与交通学院, 广东 广州 510640)

**摘要：**为提高城市公交车辆行程时间的预测精度，在分析历史数据和交通流变化特性基础上，提出了一种基于人工蜂群优化的极限学习机的组合预测模型(artificial bee colony- extreme learning machine, ABC-ELM)。首先，基于 GPS 等数据提取站间距离、时间周期及天气情况等动静态特征因素；其次，推算出公交车辆的站点停靠时间；接着，将人工蜂群优化算法(artificial bee colony algorithm, ABC)嵌入到传统极限学习机算法(extreme learning machine, ELM)中，以解决其在行程时间预测中收敛速度慢、初始权值和阈值选择困难的问题；最后，基于 ABC-ELM 算法预测公交车在目标路段的行程时间。以深圳市 620 路公交车的真实运营数据为基础进行了方法验证。结果表明，与广泛采用的 BP 神经网络、SVM 和 ELM 相比，本文所提方法在不同道路环境中均能保持较低的预测误差（RMSE 误差：高峰/平峰为 11.91/8.72，工作日/非工作日为 11.46/9.54，晴天/雨天为 10.83/12.31。决定系数  $R^2$ ：高峰/平峰为 0.87/0.92，工作日/非工作日为 0.83/0.88，晴天/雨天为 0.89/0.85），鲁棒性较强，更适用于复杂城市道路环境中的干线公交车辆的行程时间预测。

**关键词：**城市交通；公交车辆；行程时间预测；极限学习机；人工蜂群算法

**中图分类号：**U491 **文献标志码：**A

## Bus Travel Time Prediction Based on Extreme Learning Machine Optimized by Artificial Bee Colony Algorithm

XU Lunhui\*, SU Nan, PIAN Yuzhuang, LIN Peiqun

(School of Civil Engineering and Transportation, South China University of Technology, Guangzhou Guangdong  
510640, China)

**Abstract:** In order to improve the prediction accuracy of bus travel time, a combined prediction model based on artificial bee colony optimization and extreme learning machine (artificial bee colony-extreme learning machine, ABC-ELM) has been proposed after analyzing historical data and the characteristics of traffic flow. First, dynamic and static characteristics like distance between stations, time period and weather conditions are extracted using IC card and GPS data; after that the dwell time of the station is calculated; then the artificial bee colony optimization algorithm (ABC) is embedded in the traditional extreme learning machine algorithm (ELM) to solve the problem of slow convergence speed and difficulty in selecting initial weights and thresholds ELM has in prediction; finally, the travel time of the bus on target road section is predicted using the ABC-ELM algorithm. The model is verified based on the real operating data of Shenzhen Bus 620. The results show that, compared with the widely used BP neural network, SVM and ELM, the method proposed in this paper can maintain lower prediction errors in different road environments and has strong robustness (the RMSE error in peak/off-peak hour is 11.91/8.72, in workday/non-work day is 11.46/9.54, in sunny/rainy day is 10.83/12.31; the coefficient of determination  $R^2$  in peak/off-peak hour is 0.87/0.92 in workday/non-work day is 0.83/0.88, in sunny/rainy day is 0.89/0.85), which makes it more suitable for travel time prediction in complex urban road environment and for main line bus.

**Keywords:** Urban traffic; Public bus; Travel time prediction; Extreme learning machine; Artificial bee colony algorithm

收稿日期：2020-07-31

修订日期：2020-12-18

基金项目：国家自然科学基金(61572233)，广东省科技计划项目(2017B030307001)，广东大学生科技创新培育专项资金资助项目(pdjh2020a0030)

通信作者：许伦辉(1965—)，男，江西南康人，华南理工大学教授，博导。E-mail: lhxu@scut.edu.cn

公交汽车到达时间信息服务是先进公共交通系统(advanced public transportation system, APTS)的一个重要组成部分,可以帮助乘客更好地规划行程安排,最大限度地减少等待时间,继而提升城市公共交通系统的运营服务质量<sup>[13]</sup>。因此,如何即时、准确地预测公交行程时间一直都是国内外学者关注的热点问题<sup>[1-9]</sup>。在过去的几十年中,已经开发了各种模型和算法来预测公交的行程时间。一般来说,可分为3类:历史平均模型<sup>[10]</sup>、回归模型(regression models)<sup>[11]</sup>、基于卡尔曼滤波的模型<sup>[4]</sup>、以及包括人工神经网络(artificial neural network, ANN)模型和支持向量机(support vector machines, SVMs)在内的机器学习模型<sup>[6-9]</sup>。Jeong等<sup>[10]</sup>将相邻两站平均到站时间的差值减去平均停站时间作为两站间的行程时间,建立了历史平均模型。由于该模型假定过去和当前的交通状态变化不大,因此预测结果在交通量较小的支路站点才较为可靠。Kviesis等<sup>[11]</sup>对线性回归和支持向量回归模型进行了比较,发现两者差异不显著。周雪梅等<sup>[12]</sup>采用回归分析法分析了公交车辆的运行特点,以站间路段长度和站间信号交叉口数为自变量建立了公交车辆行程时间的二元回归模型。然而其忽略了天气、时段等动态因素的影响,且回归模型选取的两个自变量不能保证严格独立。Kumar等<sup>[4]</sup>提出了一种基于卡尔曼滤波的预测模型,证明了与使用空间离散化的预测方法相比,具有更高的预测精度。在此基础上,李华明等<sup>[5]</sup>提出一种融合自适应渐消卡尔曼滤波和小波神经网络算法的组合模型,证明了组合模型的预测准确性要优于单一预测模型。

机器学习模型方面,刘迎等<sup>[7]</sup>提出了一种基于差分自回归移动平均和支持向量机的组合预测模型,证明了其更适用于短距离干线公交车辆的行程时间预测。Yu等<sup>[14]</sup>提出了一种基于相关向量机(relevance vector machine, RVM)的预测算法,该算法结合了公交首日、出行时间和前几站乘客需求的时间序列来预测公交发车间隔。苗旭等<sup>[8]</sup>提出一种双层前向型神经网络(back propagation neural network, BPNN)的预测模型。该模型首先利用静态变量初始预测公交到站时间,接着结合车辆实时运行状态动态地调整期到站时间,并证明了在雨天也具有较强的稳定性。Yu等<sup>[15]</sup>分别对SVM、ANN、K近邻算法和线性回归4种常用预测方法进行了全面比较,得出结论:机器学习模型虽然能取得较高的准确度,但其存在计算复杂度较高的问题,难以实现对大规模的样本训练。对此,宋现敏等<sup>[6]</sup>利用极限学习机(extreme learning machine, ELM)建立了行程时间预测模型,并证明了ELM在满足精确度前提下拥有着更快训练速度与可靠性。但该模型只考虑了公交车数量和历史天数,偏向于历史静态数据预测,没有考虑到路段长度、天气等动态因素对行程时间的影响。此外,模型中极限学习机的权值是随机生成的,自适应性还有待提高<sup>[16]</sup>。

综上,基于机器学习的预测模型虽能较好地拟合公交行程时间预测问题中的非线性、非平稳的时间序列数据,但传统的机器学习算法计算复杂度较高,而单一极限学习机模型初始值和权值选择较难。针对这一问题,本研究提出一种基于人工蜂群优化极限学习机(artificial bee colony-extreme learning machine, ABC-ELM)的公交车辆行程时间预测模型。模型的特征向量选择方面,综合考虑历史数据、站间距离、时间周期及天气情况等动静态因素;模型的求解方面,将人工蜂群算法(artificial bee colony, ABC)嵌入到ELM中,将初始值和权值的参数寻优问题转化为寻找蜜蜂最佳花蜜的过程,最终在ABC的可行解空间中优化ELM的初始值和权值。最后,基于深圳市真实公交运营数据开展实例分析,对模型的有效性和精度进行验证。

## 1 问题厘清及基本假设

### 1.1 问题厘清

早期研究主要从交叉口延误时间和站点停靠时间2个角度出发考虑,建立公交行程时间预测模型,如文献[17]。但是,在一个单一预测模型框架中,同时对这2个因素进行建模并不是件易事。近年来,随着自动车辆定位(automatic vehicle location, AVL)系统已被公交公司广泛采用,为公交行程时间预测提供了更好的数据环境。受Yu等<sup>[15]</sup>和He等<sup>[2]</sup>工作的启发,本研究将公交车辆的站点间的运行时间与站点内的停靠时间进行分开预测。这样做的目的是减少单一预测模型的建模复杂度,同

时尽可能减少公交车辆延迟/提前到达站点或延迟/提前离开站点造成的误差影响。在前期工作中<sup>[18]</sup>, 我们已经证明了车辆位置、公交车辆站上下车乘客数量以及公交车辆到站/离站时间的实时信息可以从 AVL 系统中获知, 并给出了详细的预测方法。在此基础上, 本研究将公交行程时间的预测问题转化为: 求公交车辆上一站点离站时间与下一站点到站时间之间的差值<sup>[19, 20]</sup>。




图1 公交线路示意

Fig.1 Schematic of a bus route with several stops

为了更好地理解该预测问题的建模思路, 图1显示了一个假设的公交线路示意图。假想的公交线路被分成了许多个公交站之间的连接。当某一路公交车辆  $n$  离开站点  $m$  时, 基于文献[21]所提方法可从 AVL 系统中推算其实际出发时间。基于人工蜂群优化极限学习机的公交车辆行程时间预测模型将预测其在站点  $m$  和站点  $m+1$  之间的行程时间  $T_{n,(m,m+1)}$ 。随后, 公交车辆到达下一站点  $m+1$  的时间可以通过式(1)确定。

$$A_{n,(m+1)} = D_{n,(m)} + T_{n,(m,m+1)}, \quad (1)$$

式中:  $A_{n,(m+1)}$  是公交车辆  $n$  到达站点  $m+1$  的预测到站时间;  $D_{n,(m)}$  是公交车辆  $n$  离开站点  $m$  的预测离站时间;  $T_{n,(m,m+1)}$  是公交车辆  $n$  在站点  $m$  和站点  $m+1$  之间的预测行程时间。

## 1.2 基本假设

预测公交行程时间的关键影响因素由 5 个部分组成: ①编制, 包括路况、公交线路线形和站点位置、交叉口信号控制和车辆工况; ②运行, 包括车辆时刻表和车头时距、时间点; ③乘客, 包括乘客的需求和期望; ④驾驶员行为, 如风险偏好; ⑤环境, 包括天气条件和交通模式<sup>[9]</sup>。结合已有文献的研究成果<sup>[5-8]</sup>, 本研究对收集到的 AVL 公交运营数据的统计特征进行了研究, 验证了 4 个基本假设: ①不同时段的公交出行规律不同; ②工作日和周末的公交出行规律不同; ③工作日内同一天的公交出行规律是具有周期性的, 比如这周五与上周五; ④不同路段的公交出行规律不同。此外, 本研究认为对于特定路段, 在不考虑驾驶人个体差异的情况下, 影响公交行程时间的直接因素是路段交通状态, 故后续研究中将选择能反映交通状态及道路通行能力的特征向量。

## 2 人工蜂群-极限学习机算法的基本原理

### 2.1 极限学习机算法

极限学习机算法(extreme learning machine, ELM)由南洋理工大学黄广斌教授于 2006 年提出的一种新的机器学习方法<sup>[23]</sup>。研究表明, 它在求解单隐层前馈神经网络(single-hidden layer feedforward neural network, SLFN)时能够在兼顾模型泛化性能的情况下显著提高运算速度。ELM 和传统的前馈神经网络(back propagation, BP)网络最大的区别在于: ELM 在随机初始化输入层和隐含层间的连接权值以及偏置值后, 通过求最小范数最小二乘解的形式一次确定隐含层和输出层的连接权值。而 BP 需要利用梯度下降法将实际输出和目标输出之间的误差通过反向传播反复调整, 直到达到要求的误差精度。因此 ELM 具有学习速度更快, 调节参数更少, 泛化能力更强等优点, 同时还避免了 BP 算法容易陷入局部最值、过拟合等劣势。

其计算步骤为<sup>[23]</sup>:

**Step 1** 确定输入和输出向量的长度  $N$  和  $M$ , 以及隐含层神经元的个数  $L$ , 输入  $E$  个行程时间样



本  $(\mathbf{x}_j, \mathbf{y}_j), j=1, 2, \dots, N$  进行学习。其中,  $\mathbf{x}_j = (\mathbf{x}_{j1}, \mathbf{x}_{j2}, \dots, \mathbf{x}_{jM})^T, \mathbf{y}_j = (\mathbf{y}_{j1}, \mathbf{y}_{j2}, \dots, \mathbf{y}_{jM})^T$ ;

**Step 2** 随机生成输入层和隐含层之间的连接权值  $\mathbf{W}$  和隐含层神经元的偏置  $\mathbf{b} = (b_1, b_2, \dots, b_L)^T$ , 确定隐含层激活函数  $g(x)$  的类型;

**Step 3** 计算隐含层神经元的输出矩阵  $\mathbf{H} = \sum_{l=1}^L g(\mathbf{w}_l \cdot \mathbf{x}_j + \mathbf{b}_l), j=1, 2, \dots, N$ ;

**Step 4** 由于 ELM 能以零误差逼近目标输出, 所以令  $\mathbf{H}\boldsymbol{\beta} = \mathbf{Y}$ , 其中  $\mathbf{Y}$  是目标输出矩阵,  $\boldsymbol{\beta}$  是隐含层和输出层之间的连接权值。由此可解得  $\boldsymbol{\beta}^* = \mathbf{H}^+ \mathbf{Y}$ 。其中  $\mathbf{H}^+$  是矩阵  $\mathbf{H}$  的 Moore-Penrose 广义逆矩阵,  $\boldsymbol{\beta}^*$  是  $\boldsymbol{\beta}$  的最小范数最小二乘解。

**Step 5** 基于 Step4 解得的  $\boldsymbol{\beta}^*$ , 可通过下式(2)计算行程时间预测值  $\mathbf{y}^*$ , 即

$$\mathbf{y}^* = \sum_{j=1}^N \sum_{l=1}^L g(\mathbf{w}_l \cdot \mathbf{x}_j + \mathbf{b}_l) \boldsymbol{\beta}_l^* \quad (2)$$

不足的是, 传统的 ELM 算法存在收敛速度慢、初始权值和阈值选择困难的问题, 这大大限制了其应用价值<sup>[16]</sup>。为此, 本研究提出将 Karaboga 等<sup>[21]</sup>在 2005 年提出的人工蜂群算法(Artificial Bee Colony, ABC)嵌入到 ELM 算法中, 利用其快速的全局搜索能力, 优化 ELM 网络的输入权值、隐藏节点偏差值和网络的输出权值。

## 2.2 人工蜂群优化算法

人工蜂群算法(artificial bee colony, ABC)是 Karaboga 等<sup>[24]</sup>在 2005 年为优化数值问题而提出的。该算法模拟蜜蜂摆臂的智能觅食行为。这是一个非常简单的、基于随机优化算法的三维种群。该算法将全局寻优问题转换成蜂群寻找具有最高适应度蜜源的问题。每个蜜源对应一个可行解, 蜜源的适应度对应可行解的适应度。算法引入雇佣蜂、围观蜂和侦查蜂 3 种蜂群寻找蜜源。雇佣蜂寻找蜜源并留下蜜源的适应度信息, 围观蜂通过雇佣蜂留下的信息选择蜜源并跟新适应度信息, 侦查蜂放弃适应度信息长期不跟新的蜜源随机寻找新蜜源。ABC 算法在寻优过程中仅以适应度为依据不需要额外信息, 也对寻优函数的种类没有要求, 具有控制参数少, 搜索精度高, 鲁棒性强的特点。

其计算步骤为<sup>[24]</sup>:

**Step 1** 初始化蜜源的数量, 位置和适应度, 初始化蜂群的个数, 最大尝试次数  $l_{limit}$ 。假定寻优问题包含  $D$  个参数, 蜜源的数量为  $K$ 。蜜源  $c$  的位置  $X_c = (x_{c1}, x_{c2}, \dots, x_{cD})$  由式(3)确定,

$$X_c = V + \text{rand}(0,1)(U - V) \quad (3)$$

式中  $V$  和  $U$  分别是求解空间的下界和上界。蜜源  $c$  的适应度  $F_c$  由式(4)确定,

$$F_c = \frac{1}{1 + f_c} \quad (4)$$

式中  $f_c$  是目标寻优函数在蜜源  $X_c$  处的值。雇佣蜂和围观蜂的数量取为蜜源数一半  $K/2$ 。

**Step 2** 雇佣蜂阶段。雇佣蜂一一探索蜜源, 在蜜源  $c$  的周围随机选择不同蜜源  $p$  按照式(5)产生一个新的蜜源位置,

$$X_{new} = X_c + \phi(X_c - X_p) \quad (5)$$

式中  $\phi$  是 -1 到 1 的随机数, 当新蜜源  $X_{new}$  的适应度要优于原始解时, 按照贪心选择接受新蜜源, 否则维持不变。雇佣蜂搜寻完所有蜜源后结束 Step 2。

**Step 3** 围观蜂阶段。围观蜂根据雇佣蜂留下的蜜源适应度, 按照式(6)生成探索蜜源  $X_c$  的概率  $P_{c_s}$ 。

$$P_c = \frac{F_c}{\sum_{i=1}^K F_c}, \quad (6)$$

(6)

围观蜂按照轮盘赌方法，生成一个 0 到 1 的随机数  $R_c$ ，如果  $R_c$  小于  $P_c$ ，则围观蜂探索此蜜源，并照式(6)更新蜜源位置并通过贪心选择决定保留新蜜源还是舍弃。

**Step 4** 侦查蜂阶段。对一个蜜源，如果生成的新蜜源的适应度总是小于原蜜源，且这样的尝试次数  $q$  经超过了最大尝试次数  $l_{\text{limit}}$ ，则舍弃该蜜源由侦查蜂通过式(3)随机生成一个新的蜜源。

**Step 5** 记录适应度最优蜜源，判断是否达到终止条件，如果达到进入 Step 6，否则循环执行 Step2 至 Step4 阶段。

**Step 6** ABC 算法结束，输出最优的蜜源。

### 2.3 改进人工蜂群-极限学习机算法

针对极限学习机收敛速度慢、初始权值和阈值选择困难的问题，本研究提出了一种基于人工蜂群优化的极限学习机的组合算法(artificial bee colony-extreme learning machine, ABC-ELM)。该算法以 ELM 算法为基础，引入 ABC 算法优化网络输入权值，隐藏节点偏差和 ELM 导出网络输出权值。ABC-ELM 算法结合了 ABC 算法的鲁棒全局搜索能力和 ELM 算法的强非线性映射和学习能力，其主要思想是利用 ELM 产生的误差作为指导选择的适应度，然后将优化后的网络参数作为 ELM 算法的输入，最后不断训练 ELM，直到总误差小于期望误差  $\varepsilon$ 。逻辑结构如图 2 所示。

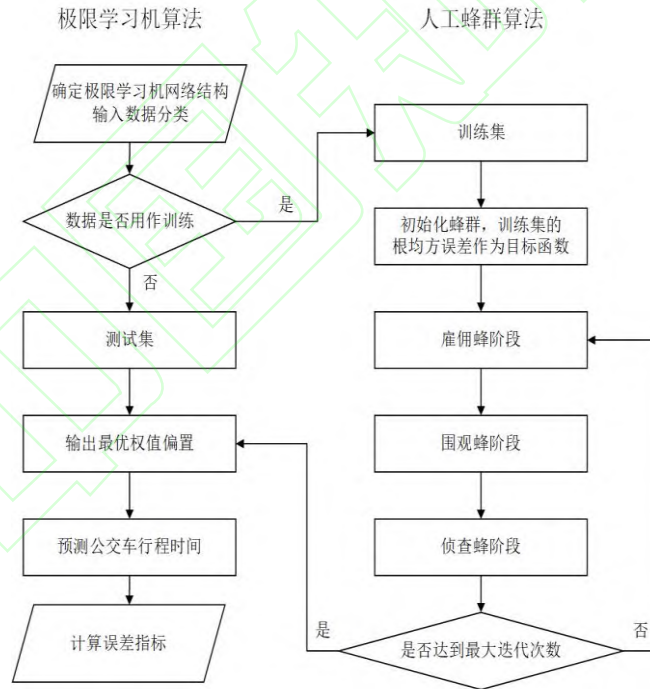


图 2 人工蜂群算法优化极限学习机模型流程

Fig.2 Flow chart of extreme learning machine optimized by artificial bee colony algorithm

具体计算步骤为：

**Step 1** 初始化。随机产生  $S_N$  个食物源，设置初始化最大迭代次数  $M_{CN}$ 、最大尝试次数  $l_{\text{limit}}$  和蜂群规模，其中每个食物源  $\theta_c (c=1, 2, \dots, S_N)$  的位置为一组输入层权值和隐含层阈值，有

$$\theta_c = [w_{11}, \dots, w_{1mm}, w_{21}, \dots, w_{2mm}, \dots, w_{nn1}, \dots, w_{nn,mm}, b_1, \dots, b_{mm}] \quad (7)$$

式中,  $w_{nn,mm}$  初始化为[-1,1]之间的随机值,  $b_{mm}$  初始化为[0, 1]之间的随机值,  $nn$  和  $mm$  分别是输入层和隐含层节点数。

**Step 2** 计算适应度。适应度函数计算公式为

$$F_c = \frac{1}{1 + e_c}, \quad (8)$$

式中  $e_c$  为第  $c$  个食物源对应的 ELM 输入层权值和隐含层阈值训练时的根均方误差(root mean squared error, RMSE),  $e_c$  的计算公式为

$$e_c = \sqrt{\frac{1}{N} \sum_{c=1}^N (y'_c - y_c)^2}, \quad (9)$$

式中  $y'_c$ 、 $y_c$  和  $N$  分别为实际输出值、期望输出值和行程时间样本数。

**Step 3** 所有雇佣蜂选择完食物源后, 回到蜂巢与观察蜂分享食物源的信息, 观察蜂根据第  $c$  ( $c=1, 2, \dots, S_N$ ) 个食物源的概率  $P_c$  选择搜索的对象。然后按式(5)在第  $c$  个食物源邻域内搜索新的食物源, 保留适应度值大的食物源。

**Step 4** 某一食物源在  $l_{\text{limit}}$  次迭代后仍未更新, 该食物源对应的蜜蜂按式(3)搜索新的食物源。

**Step 5** 重复步骤 Step 2~Step 4, 直到迭代次数达到  $M_{CN}$ , 循环结束。

**Step 6** 将循环中适应度值最大的食物源对应的参数, 作为 ELM 网络最优的输入层权值和隐含层阈值。

### 3 基于 ABC-ELM 算法的公交行程时间预测

#### 3.1 特征向量的选择

已有文献表明<sup>[14]</sup>, 有某些关键因素会影响公交车的到达时间, 如早高峰、恶劣天气造成的不可预测的交通状况、行程距离、交通事故等。在此基础上, 韩勇等将影响因素分为 2 种<sup>[22]</sup>: 一种是与路段相关的静态因素, 包括站点间的路段距离, 信号交叉口数量, 站点路段特性等, 这些因素的取值基本维持不变, 随机性较弱; 另一种是与时间相关的动态因素, 包括天气情况, 高峰/平峰, 到站时间等, 这些因素能更好地体现预测实时性。本研究预测算法在特征向量选择上, 综合考虑动静态因素, 从而确保模型的预测精度。静态因素选取方面, 主要有: 站点、站间距离、信号交叉口数量、路段所在区域, 动态因素选取方面, 主要有: 时段、星期、节假日情况、天气、上周运行时间、昨天运行时间、站点停靠时间。

表 1 预测模型的特征向量选择及其原因

Tab.1 Input variables of the prediction model and reasons for selection

输入特征向量		向量提取理由
静态因素	站点	不同站点对应的站点到站时间不同
	路段距离	公交车辆运行速度波动不大, 路段距离对行程时间有直接影响
	信号交叉口数量	公交车在交叉口有一定概率排队造成行程时间增加
	路段所在区域	不同区域的道路状况不同, 导致其行程时间也会有差异, 通常上距离城市中心越近的路段交通流量越大 <sup>[22]</sup>
动态因素	时段	高峰期和平峰期的交通量和道路拥堵情况会有显著差异
	星期	工作日与非工作日的客流量会有显著差异
	天气情况	不同天气情况对交通流量的影响不同, 晴天的公交车辆行程时通常比雨天要小 <sup>[22]</sup>
	节假日情况	节假日的交通出行量与非节假日有较为明显的差异 <sup>[18]</sup>
	昨日运行时间	在一定时期内天气的变化情况可以看成是连续的, 在某种程度上一个站点昨天的行程时间与今天的行程时间有一定的相关性

上周运行时间	上周和今日输入变量存在一定相似，具有周期性
站点停靠时间	不同站点、不同时段的公交停靠时间是不同的，其能在某种程度上反映该站点在该段时间内的上下车人数 <sup>[25]</sup>

### 3.2 基于 ABC-ELM 算法的预测流程

本研究将人工蜂群算法嵌入到极限学习机中，通过分析历史数据中目标班次公交的行程时间预测值，结合当前城市交通流变化规律，提出了一种基于人工蜂群优化极限学习机(artificial bee colony-extreme learning machine, ABC-ELM)的公交车辆行程时间预测模型。针对第  $n$  班次公交车辆的行程时间组合预测模型技术方案见图 3。具体步骤为：

① 站点静态特征的提取。获得第  $n$  班次公交车辆相关静态信息，包括：站点、站间距离、信号交叉口数量、路段所在区域。

② 站点动态特征的初步提取。基于路段行程时间历史数据（GPS 数据、IC 卡数据），经过数据清洗、数据关联、数据提取等步骤，获得第  $n$  班次公交车辆经过各站点初步的动态交通状态信息，包括：时段、星期、节假日情况、天气、上周运行时间、昨天运行时间。

③ 站点停靠时间的推算。基于文献[18]所提方法可从 AVL 系统中提取第  $n$  班次公交车辆在  $m$  站点的到站时间和离站时间。在此基础上，可以推算到公交车辆在  $m$  站点的停靠时间。

④ 将步骤①~③提取得到的站点动静态特征输入到 ABC-ELM 算法中，基于式(2)~(9)，计算得到第  $n$  班次公交车辆在  $m$  站点与  $m+1$  站点之间的初步预测行程时间。

⑤ 真实行程时间的获取。基于式(1)和步骤③的计算结果可以得到第  $n$  班次公交车辆在  $m$  站点与  $m+1$  站点之间的真实行程时间。

⑥ 计算第  $n$  班次公交车辆在  $m+1$  站点初步预测行程时间与真实行程时间的误差，并将其反向传播到 ABC-ELM 网络中，不断迭代，直到其误差小于设定的阈值。

⑦ 将其最终输出结果，作为公交车辆到站到达各站点的最终预测行程时间。

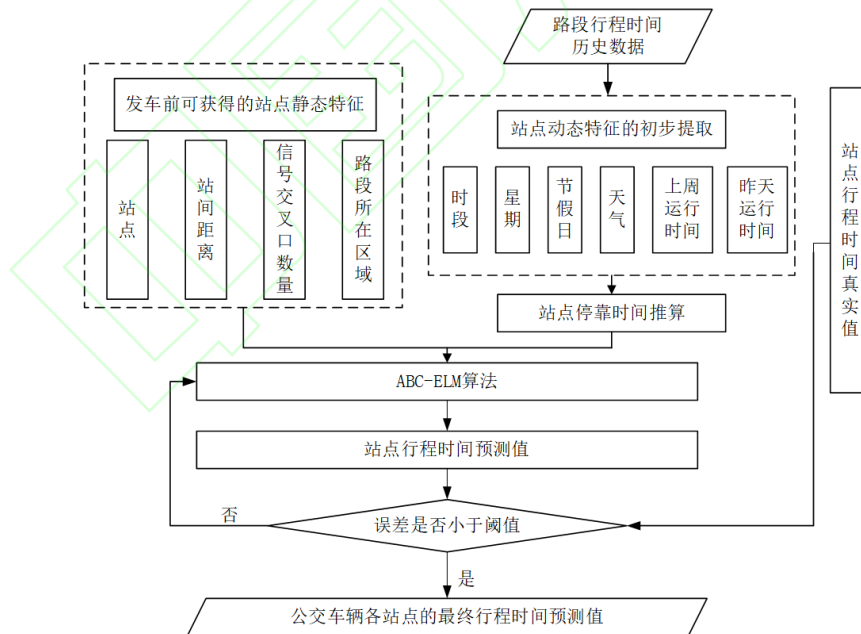


图 3 ABC-ELM 预测模型结构

Fig.3 ABC-ELM prediction model structure diagram

## 4 实证分析

### 4.1 数据来源及预处理



本研究将所提方法应用于深圳市 620 路公交车线路上, 选取 2018 年 10 月 8 日至 2018 年 10 月 31 日的 GPS 数据作为原始数据, GPS 数据的字段包括定位时间、定位时刻、线路、车牌、经度、纬度、速度和方向角等。首先以 50 m 的距离为阈值, 通过经纬度计算公交站点 GIS 位置和 GPS 定位点的距离, 确定 GPS 记录的到站信息, 并由此推断公交车的上下行方向。在得到到站信息的基础上, 结合深圳公交在到达和离开站点时会连续发出两条 GPS 的特性, 将 50 m 以内最早发出的 GPS 记录作为该站的到达时间, 最迟的记录作为离去时间, 从而获得停靠时间等信息<sup>[21,26]</sup>。

在特征向量提取方面, 为了确定路段所在区域, 本研究依据城市交通流理论中, 离市中心越近, 交通流量就相应越大的特点<sup>[22]</sup>, 将所在区域分为住宅区、工业区和商业区共 3 种类型。路段距离通过 GPS 地理信息获得。信号交叉口数量通过实地调查获取。天气情况通过历史天气查询网站获得, 分为晴、小雨和大雨 3 个级别<sup>[25]</sup>。出于简化考虑, 选取 14:00—16:00 为平峰时段, 17:00—19:00 为高峰时段。每天平峰和高峰共提取 10 趟完整的公交车行程时间记录, 最终从匹配好公交站点的 GPS 记录中提取了 160 组 14:00—19:00 时间段的行程时间记录。将其中的 133 组作为训练集, 27 组作为测试集。部分实验数据样例如表 2 所示。

表 2 实验数据样例  
Tab.2 Sample of experiment data

站点	路段 距离	信号交叉 口数量	路段所在 区域	时段	星期	天气情况	节假日 情况	昨日运行 时间/s	上周运行 时间/s	站点停靠 时间/s
台菱大厦	600	1	工业区	15:05	工作日	小雨	非节假日	81	86	15
松和小学	1 300	2	商业区	18:58	工作日	晴	非节假日	294	339	23
岗头村	330	0	工业区	16:49	工作日	大雨	非节假日	75	82	18
利金城	668	1	住宅区	17:12	非工作日	小雨	节假日	130	118	26

#### 4.2 模型参数的校准

经过多次取不同的参数试验, 极限学习机模型设置成 3 层 10-10-1 的结构, 即 10 个输入节点, 10 个隐含层节点, 1 个输出节点。隐含层的激活函数选择 Sigmoid 函数, 输入层和隐含层之间的连接权值和偏置共有  $10 \times 10 + 10 = 110$  个, 因此蜂群蜜源的维度  $D$  为 110。蜜源的数量  $N$  设为 16, 目标函数设置成 ELM 的根均方误差, 参数的上界和下界  $V$  和  $U$  设为 1 和 0, 最大迭代次数设置为 30 次。最大尝试次数  $l_{\text{limit}}$  设置为 10 的时候预测效果最好。为了量化天气情况, 运行时段和路段所在区域的影响, 将这 3 个因素进行数值化。天气按照晴、小雨、大雨量化为 4、6、8; 路段所在区域按照住宅区、工业区、商业区分别量化为 4、6、8; 运行时段按照平峰高峰量化为 4、8; 时段转换成分钟数输入。其中星期和节假日情况按照 0-1 编码输入, 所有数据归一化后输入 ABC-ELM 模型中<sup>[6]</sup>。

#### 4.3 预测模型评价分析

为了进一步验证本文所提出的基于 ABC-ELM 预测方法的有效性及其可行性, 将本文方法与常用的 BP<sup>[22]</sup>、SVM<sup>[10]</sup>以及标准的 ELM 算法<sup>[6]</sup>进行对比, 各模型的变量选择如表 3 所示。SVM 为仅考虑静态因素的预测模型, 并未对路段的动态影响因素进行更深层次的挖掘<sup>[10]</sup>; BP 为近几年频繁采用的预测模型<sup>[22]</sup>; 标准的 ELM 仅考虑历史数据, 对静态影响因素考虑较少<sup>[6]</sup>。模型评价指标采用平均绝对百分比误差(mean absolute percentage error, MAPE)、平均绝对误差(mean absolute error, MAE)、根均方误差(root mean squared error, RMSE)和决定系数  $R^2$ <sup>[18]</sup>。MAPE 反映绝对误差百分比, 其值越小说明预测的效果越好; MAE 能防止正负误差相互抵消, 更全面反应预测情况; RMSE 能反应误差的离散程度;  $R^2$  是决定系数, 它能反应模型对原数据的拟合程度, 越接近 1, 模型的拟合程度越好。

表 3 模型特征变量选择表

Tab.3 Feature variables of four models

变量	模型			
	BP 神经网络	支持向量机	极限学习机模型	本文模型
站点	√	√	√	√
路段距离	√	√		√
信号交叉口数量				√
路段所在区域	√	√		√
时段	√	√	√	√
星期	√	√	√	√
天气情况	√	√		√
节假日情况	√	√		√
昨日运行时间	√		√	√
上周运行时间	√		√	√
站点停靠时间				√

#### 4.3.1 高峰/平峰时段预测结果对比

时段是影响公交行程时间的关键因素。不同时段交通流量和客流量有明显差异，通常上高峰期间的平均运行时间明显高于非高峰期。为了分析时段对预测结果的影响，选取平峰和高峰两种情况进行实验验证。高峰时段选择 10 月 10 日（星期三）18:35 至 18:58 分华为北门站至龙华富士康站路段，天气为小雨。平峰时段选择同天 15:05 分至 15:29 分华为北门站至龙华富士康站路段，天气为小雨。在其他外部因素影响基本一致的情况下，不同模型在高峰/平峰的预测误差结果，如图 4 所示，主要评价指标结果如表 4 所示。可以看出：①相对而言，高峰时段时，4 类模型对公交车辆行程时间的预测误差都偏大。其中，4 类模型的 MAPE、MAE 和 RMSE 都超过了 1 位数。这说明对于平峰时段，4 类模型的预测能力都有不同水平的下降。②从图 4 直观来看，无论是高峰时段还是平峰时段，相比与 BP、SVM、ELM 算法，本文所提 ABC-ELM 算法的预测误差波动最小，稳定性较高。③从表 4 可以看出，相比与 BP、SVM、ELM 算法，本文所提 ABC-ELM 算法能取得较优的预测精度。在平峰时段，MAPE 相对于前 3 类算法分别降低了 3.25%、7.86%、4.73%，MAE 相对于前 3 类算法分别降低了 37.9%、56.7%、48%，RMSE 相对于前 3 类算法分别降低了 39.4%、56.9%、49.6%， $R^2$  达到 0.92。即使是在 4 类模型预测误差都相对较大的高峰时段，MAPE 相对于前 3 类算法分别降低了 5.36%、7.93%、3.56%，MAE 相对于前 3 类算法分别降低了 37.1%、50.7%、29.3%，RMSE 相对于前 3 类算法分别降低了 32.8%、30.3%、24.7%； $R^2$  达到 0.87。这主要归因于 ABC-ELM 模型能提供更大的可行解范围，通过取全局最优和引进随机解的方式最终确定权值，预测效果较好；相比之下 BP 算法的梯度下降容易陷入局部最优，SVM 的回归结果与支持向量数量有关，而 ELM 由于权值随机预测效果也稍弱。




图 4 高峰/平峰公交车行程时间预测结果

Fig.4 Prediction results of bus travel time during peak and off-peak time

表 4 高峰/平峰不同模型评价指标

Tab.4 Evaluation index of different model during peak and off-peak time

模型	高峰				平峰			
	MAPE/%	MAE/%	RMSE/%	$R^2$	MAPE/%	MAE/%	RMSE/%	$R^2$
BP	15.87	16.63	17.73	0.80	10.83	11.58	14.39	0.86
SVM	18.44	21.18	22.63	0.75	15.44	16.60	20.24	0.81
ELM	14.07	14.79	15.82	0.82	12.31	13.83	17.30	0.84
ABCELM	10.51	10.45	11.91	0.87	7.58	7.19	8.72	0.92

#### 4.3.2 工作日/非工作日预测结果对比

工作日和非工作日行程时间的时变规律有所不同。通常上，工作日会有明显的上下班峰值，因而行程时间波动相对会较大。为了剖析工作日和非工作日对预测结果的影响，本研究选取工作日和非工作日两种情况进行实例分析。工作日选取 10 月 11 日（星期四）14 时至 18 时 30 分五和东门—金荣达工业园区间，工作日选取 10 月 14 日（星期天）同一路段、同一时间、同一区间。在其他条件不变的情况下，预测结果如图 5 所示，主要评价指标如表 5 所示。可以看出：①在工作日，本文提出的算法在 MAPE 指标上相对于 BP、SVM、ELM 算法分别降低了 1.58%、1.15%、0.93%；MAE 相对于前 3 类算法分别降低了 25.8%、20.2%、14.0%；RMSE 相对于前 3 类算法分别降低了 32.0%、22.0%、21.2%； $R^2$  达到 0.83。在非工作日，本文提出的算法在 MAPE 指标上相对于前 3 类算法分别降低了 1.79%、0.37%、1.07%；MAE 相对于前 3 类算法分别降低了 43.6%、23.6%、32.7%；RMSE 相对于前 3 类算法分别降低了 29.4%、14.3%、23.0%， $R^2$  达到 0.88。②横向对比来看，工作日的各种模型误差指标都低于非工作日模型，这说明 4 类算法在工作日的预测效果要稍微弱于非工作日，可能是因为工作日流量的分布更加不均匀，容易在上下班高峰期产生极值影响预测效果。但整体来说，无论是工作日还是非工作日，本文所提算法在这 4 类算法中都能取得较优的预测效果。这是因为 ABC-ELM 模型在处理非线性回归问题时采用的 ABC 算法更适合求解多维数值问题寻优问题<sup>[24]</sup>，而 BP 模型通过误差反向传导，SVM 模型受限于核函数的选择，ELM 模型的预测效果也受初值的波动影响。

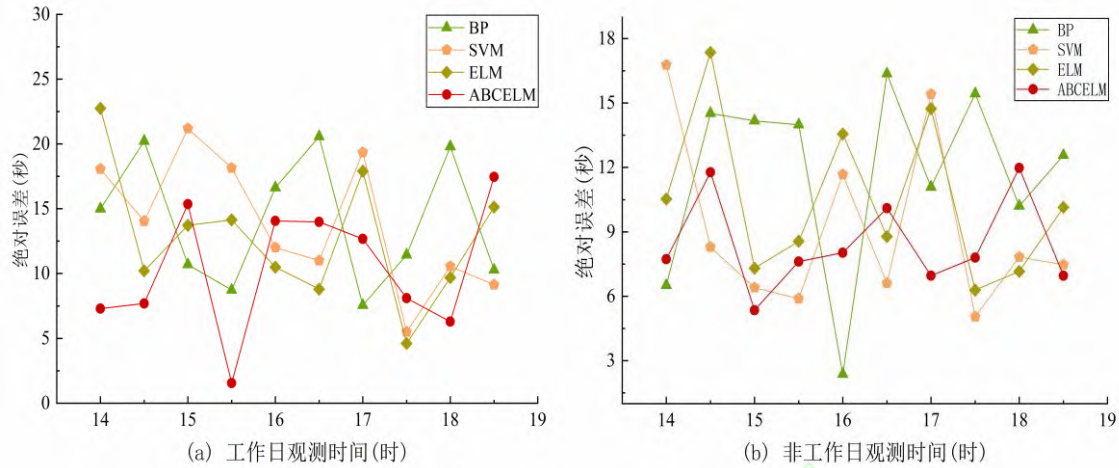


图5 工作日和非工作日公交车行程时间预测结果

Fig.5 Prediction results of bus travel time during workday and non-workday

表5 工作日不同模型评价指标

Tab.5 Evaluation index of different model during workday and non-workday

工作日					非工作日			
模型	MAPE%	MAE	RMSE	$R^2$	MAPE%	MAE	RMSE	$R^2$
BP	6.21	14.08	16.86	0.74	4.83	12.77	13.51	0.81
SVM	5.78	13.08	14.71	0.80	3.41	9.43	11.13	0.85
ELM	5.56	12.14	14.55	0.80	4.11	11.06	12.39	0.84
ABCELM	4.63	10.44	11.46	0.83	3.04	7.20	9.54	0.88

#### 4.3.3 不同天气情况预测结果对比

行程时间也受天气的影响,为了分析降雨对预测结果的影响,根据是否有雨将天气情况分为晴天与雨天两类<sup>[8]</sup>。晴天样本选取10月10日(星期三)14时至18时30分华为北门——华为电子站区间,雨天样本选取10月15日(星期一)同一时间同一区间,天气为小雨。由文献[18]可知,工作日居民出行客流量较为一致,在其他条件不变的情况下,预测结果如图6所示,主要评价指标如表6所示。可以看出:①在晴天,本文提出的算法在MAPE指标上相对于BP、SVM、ELM算法分别降低了5.85%、4.83%、3.02%;MAE相对于前3类算法分别降低了49.2%、44.1%、27.5%;RMSE相对于前3类算法分别降低了36.5%、29.1%、11.5%; $R^2$ 达到0.89。这说明本文算法相较于其他3类模型,能在晴天天气下取得较优的预测精度。②横向对比来看,4类模型在雨天情况下,预测效果都不如晴天下理想,这与文献[8]的研究结果较为一致。这可能是因为雨天情况易使驾驶员受视野干扰,站间运行速度波动较大,导致其行程时间也易产生较大的波动,从而影响模型的预测精度。然而,即使在雨天,本文提出的算法在MAPE指标上相对于前3类算法分别降低了3.85%、4.98%、1.84%;MAE相对于前3类算法分别降低了44.4%、47.6%、17.3%;RMSE相对于前3类算法分别降低了40.1%、47.8%、13.7%, $R^2$ 达到0.85。这是因为ABC-ELM模型能更好的通过侦查蜂阶段寻找新解的方式避免陷入局部最优解,从而在行程时间波动较大时提高预测的精度。



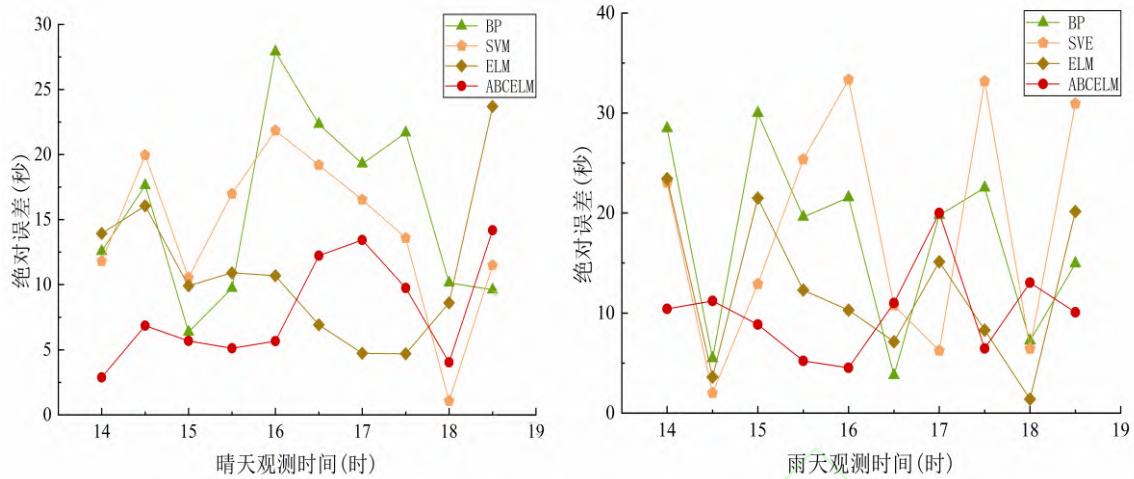


图6 晴天和雨天公交车行程时间预测结果

Fig.6 Prediction results of bus travel time during sunny and rainy day

表 6 不同天气模型评价指标

Tab.6 Evaluation index of different model during sunny and rainy day

模型	晴天				雨天			
	MAPE%	MAE	RMSE	$R^2$	MAPE%	MAE	RMSE	$R^2$
BP	11.10	15.72	17.08	0.80	12.42	18.32	20.58	0.76
SVM	10.08	14.29	15.29	0.82	13.55	19.41	23.58	0.71
ELM	8.27	11.01	12.24	0.86	10.41	12.32	14.27	0.82
ABCELM	5.25	7.98	10.83	0.89	8.57	10.18	12.31	0.85

#### 4.3.4 不同路段所在区域预测结果对比

路段所在区域也是影响行程时间的一个重要因素，文献[25]指出离市中心越近，交通流量就相应越大。在此基础上，本研究依据路段特性，将 620 路公交的所有站点分为住宅区（坂兴路口至龙华富士康），工业区（台菱大厦至华为软件站），商业区（松和小学至东边）3 种类型。选取 10 月 15 日（星期一）16 时 16 分至 17 点 01 分全程进行研究，3 种不同区域的预测主要指标如表 7 所示。可以看出：①4 类模型在不同路段区域的预测精度有所区别。整体来看，工业区的预测误差最小，住宅区的其次，商业区的最大。这与文献[25]的研究结论较为一致。这可能是因为工业区和住宅区大部分站点的行程时间都较小，商业区站点大部分行程时间比较大，此外商业区交通量大，易发生交通拥堵从而导致班次延误。②从每个区域单独来看，本文所提算法相较于其他 3 类模型都能取得较优的预测精度。相对于 BP、SVM、ELM 算法，在工业区，MAPE 分别降低了 3.24%、1.99%、8.22%， $R^2$  达到 0.93；MAE 分别降低了 26.7%、27.6%、46.3%；RMSE 分别降低了 31.9%、25.0%、51.2%；在住宅区，MAPE 分别降低了 1.40%、5.30%、3.04%；MAE 分别降低了 8.9%、25.5%、25.5%；RMSE 分别降低了 16.1%、27.1%、30.8%， $R^2$  达到 0.91；在商业区，MAPE 分别降低了 0.24%、6.38%、2.29%；MAE 分别降低了 9.7%、40.6%、19.3%；RMSE 分别降低了 12.8%、39.9%、19.0%， $R^2$  达到 0.83。整体而言对比其他 3 类算法，本文所提算法泛化能力更强，更能适用于不同道路场景的路段区域。

表 7 不同区域模型评价指标

Tab.7 Evaluation index of different model in different area

模型	工业区				住宅区				商业区			
	MAPE/%	MAE/%	RMSE/%	$R^2$	MAPE/%	MAE/%	RMSE/%	$R^2$	MAPE/%	MAE/%	RMSE/%	$R^2$
BP	10.00	11.13	10.28	0.89	12.23	10.97	12.79	0.89	14.79	22.27	24.31	0.80
SVM	8.75	11.27	9.34	0.91	16.13	13.53	14.72	0.86	20.93	33.89	35.30	0.72
ELM	14.98	15.20	14.36	0.85	13.87	13.52	15.51	0.87	16.84	24.91	26.20	0.78
ABCELM	6.76	8.15	7.00	0.93	10.83	10.07	10.73	0.91	14.55	20.10	21.20	0.83

#### 4.3.5 训练时间对比

在其他条件相同的情况下,对 4 种方法进行了 10 次重复试验,其训练时间如表 8 所示。可以看出,在这 4 类模型中,ELM 的训练时间最短,平均时间为 76.5 s。这与文献[6]的研究结论较为一致,说明 ELM 相比于 BP 和 SVM 机器学习算法,取得较优的模型运行效率。其次,较优的是本文所提 ABC-ELM 模型,平均训练时间为 110.7 s,相比 BP 算法(128 s)和 SVM 算法(255.3 s)的平均训练时间分别小 13.5%,56.6%。这可能是因为极限学习机直接通过计算广义逆矩阵的方式得到权值,而 BP 算法需要通过误差迭代确定,SVM 算法则需要通过计算最优超平面确定,导致后两者的训练时间都比极限学习机高。此外,ABC-ELM 算法是由 ABC 确定传统 ELM 的最优权值,存在参数寻优过程,导致其训练时间稍高于传统 ELM 模型。但考虑到 ABC-ELM 算法在不同环境下均能取得较高的预测精度,适当的训练时间代价成本增加是可以接受的。

表 8 不同模型运行时间

Tab.8 Training time of different model

模型	最小训练时间	最大训练时间	平均训练时间
BP	109.8	140.8	128.0
SVM	240.6	287.4	255.3
ELM	70.8	84.6	76.5
ABC-ELM	93.3	149.4	110.7

## 5 总结

本文以综合考虑站间距离、时间周期及天气情况等动静态因素,构建了一种基于人工蜂群优化的极限学习机组合预测模型(artificial bee colony-extreme learning machine, ABC-ELM)的公交行程时间预测模型,实现了多源数据下面向连续站点的公交行程时间的精准预测。实验结果表明,本文方法在不同时段、不同工作日、不同天气及不同路段区域的道路环境下,预测精度均能优于对比模型,具有良好的鲁棒性及泛化能力。这说明此方法对于我国城市复杂道路环境下的公交车辆行程时间的实时预测具有一定的实用价值。未来的工作中,将通过主成分分析法等手段对影响因素的提取进行深入分析,以期建立一套完善的特征向量选择方案。

## 参 考 文 献

- [1] YU H, CHEN D, WU Z, et al. Headway-based bus bunching prediction using transit smart card data[J]. Transportation Research Part C: Emerging Technologies, 2016, 72: 45-59. DOI: 10.1016/j.trc.2016.09.007.
- [2] HE P, JIANG G, LAM S K, et al. Travel-time prediction of bus journey with multiple bus trips[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 20(11): 4192-4205. DOI: 10.1109/TITS.2018.2883342.
- [3] MA J, CHAN J, RISTANOSKI G, et al. Bus travel time prediction with real-time traffic information[J]. Transportation

- Research Part C: Emerging Technologies, 2019, 105: 536-549. DOI: 10.1016/j.trc.2016.09.007.
- [4] KUMAR B A, VANAJAKSHI L, SUBRAMANIAN S C. Bus travel time prediction using a time-space discretization approach[J]. Transportation Research Part C: Emerging Technologies, 2017, 79: 308-332. DOI: 10.1016/j.trc.2017.04.002.
- [5] 李华民, 吴俊美, 孙棣华, 等. 基于 RFID 电子车牌数据的公交行程时间预测方法[J]. 中国公路学报, 2019, 32(8): 165-173, 182. DOI: 10.19721/j.cnki.1001-7372.2019.08.015.
- [6] 宋现敏, 刘明鑫, 马林, 等. 基于极限学习机的公交行程时间预测方法[J]. 交通运输系统工程与信息, 2018, 18(5): 136-142, 150. DOI: 10.16097/j.cnki.1009-6744.2018.05.020.
- [7] 刘迎, 过秀成, 周润瑄, 等. 基于多源数据融合的干线公交车辆行程时间预测[J]. 交通运输系统工程与信息, 2019, 19(4): 124-129, 148. DOI: 10.16097/j.cnki.1009-6744.2019.04.018.
- [8] 苗旭, 王忠宇, 吴兵, 等. 考虑前序路段状态的公交到站时间双层 BPNN 预测模型[J]. 交通运输系统工程与信息, 2020, 20(2): 127-133. DOI: 10.16097/j.cnki.1009-6744.2020.02.019.
- [9] BAI C, PENG Z R, LU Q C, et al. Dynamic bus travel time prediction models on road with multiple bus routes[J]. Computational intelligence and neuroscience, 2015, 2015. DOI: 10.1155/2015/432389.
- [10] JEONG R, RILETT R. Bus arrival time prediction using artificial neural network model[C]//Proceedings. The 7th International IEEE Conference on Intelligent Transportation Systems (IEEE Cat. No. 04TH8749). IEEE, 2004: 988-993. DOI: 10.1109/ITSC.2004.1399041.
- [11] KVIESIS A, ZACEPINS A, KOMASILOVS V, et al. Bus Arrival Time Prediction with Limited Data Set using Regression Models[C]//VEHITS. 2018: 643-647. DOI: 10.5220/0006816306430647.
- [12] 周雪梅, 杨晓光, 王磊. 公交车行程时间预测方法研究[J]. 交通与计算机, 2002(6): 12-14. DOI: 10.3963/j.issn.1674-4861.2002.06.004.
- [13] 胡郁葱, 宫曼琳, 谢映辰, 等. 网络预约出租汽车营运模式的四方博弈模型[J]. 公路交通科技, 2020, 37(2): 133-139. DOI: 10.3969/j.issn.1002-0268.2020.02.017.
- [14] YU H, WU Z, CHEN D, et al. Probabilistic prediction of bus headway using relevance vector machine regression[J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 18(7): 1772-1781. DOI: 10.1109/TITS.2016.2620483.
- [15] YU B, LAM W H K, TAM M L. Bus arrival time prediction at bus stop with multiple routes[J]. Transportation Research Part C: Emerging Technologies, 2011, 19(6): 1157-1170. DOI: 10.1016/j.trc.2011.01.003.
- [16] SONG C, FENG L, LIN X, et al. Artificial Bee Colony (ABC) Optimization Algorithm for Training Extreme Learning Machine[J]. communications in control science & engineering, 2014, 2. DOI: 10.1007/978-3-540-73729-2\_30.
- [17] SHALABY A, FARHAN A. Prediction model of bus arrival and departure times using AVL and APC data[J]. Journal of Public Transportation, 2004, 7(1): 3. DOI: 10.5038/2375-0901.7.1.3.
- [18] HUANG Z, XU L, LIN Y, et al. Citywide Metro-to-Bus Transfer Behavior Identification Based on Combined Data from Smart Cards and GPS[J]. Applied Sciences, 2019, 9(17): 3597. DOI: 10.3390/app9173597.
- [19] HUANG Z, XU L, LIN Y. Multi-Stage Pedestrian Positioning Using Filtered WiFi Scanner Data in an Urban Road Environment[J]. Sensors, 2020, 20(11): 3259. DOI: 10.3390/s20113259.
- [20] WU P, HUANG Z, PIAN Y, et al. A Combined Deep Learning Method with Attention-Based LSTM Model for Short-Term Traffic Speed Forecasting[J]. Journal of Advanced Transportation, 2020, 2020. DOI: 10.1155/2020/8863724.
- [21] 王芳杰, 王福建, 王雨晨, 等. 基于 LightGBM 算法的公交行程时间预测[J]. 交通运输系统工程与信息, 2019, 19(2): 116-121. DOI: 10.16097/j.cnki.1009-6744.2019.02.017.
- [22] 韩勇, 周林, 高鹏, 等. 基于 BP 神经网络的公交动态行程时间预测方法研究[J]. 中国海洋大学学报(自然科学版), 2020, 50(2): 142-154. DOI: 10.16441/j.cnki.hdx.20180285.
- [23] HUANG G B, ZHU Q Y, SIEW C K. Extreme learning machine: theory and applications[J]. Neurocomputing, 2006, 70(1/2/3): 489-501. DOI: 10.1016/j.neucom.2005.12.126.
- [24] KARABOGA D, BASTURK B. A powerful and efficient algorithm for numerical function optimization: artificial bee

- colony (ABC) algorithm[J]. Journal of global optimization, 39(3): 459-471.DOI: 10.1007/s10898-007-9149-x.
- [25] 彭新建, 翁小雄. 基于萤火虫算法优化 BP 神经网络的公交行程时间预测[J].广西师范大学学报(自然科学版), 2017, 35(1): 28-36. DOI: 10.16088/j.issn.1001-6600.2017.01.005.
- [26] 尹安藤. 基于公交 GPS 和 IC 卡数据的公交 OD 推算[D]. 哈尔滨: 哈尔滨工业大学, 2017.

